

국고채, 금리 스왑 그리고 통화 스왑 가격에 기반한 외환시장 환율예측 연구: 인공지능 활용의 실증적 증거¹⁾

A Study on Foreign Exchange Rate Prediction Based on KTB, IRS and CCS
Rates: Empirical Evidence from the Use of Artificial Intelligence

| | |
|------------------------|---------------------------------|
| 임현욱 (Hyun Wook Lim) | 연세대학교 투자정보공학 협동과정 ²⁾ |
| 정승환 (Seung Hwan Jeong) | 연세대학교 산업공학과 ³⁾ |
| 이희수 (Hee Soo Lee) | 세종대학교 경영학과 ⁴⁾ |
| 오경주 (Kyong Joo Oh) | 연세대학교 산업공학과 ⁵⁾ |

〈 국문초록 〉

본 연구는 채권시장과 금리시장의 지표를 이용한 외환시장 환율예측 모델을 만드는데 있어 어떤 인공지능 방법론이 가장 적합한지 밝혀내는데 그 목적이 있다. 채권시장의 대표 상품인 국고채와 통안채는 위험회피 상황이 올 때 대규모로 매도되어지고 그런 경우 환율이 상승하는 모습을 자주 보여주었고, 금리시장에서 통화 스왑 (Cross Currency Swap) 가격은 달러 유동성 문제가 생길 때 주로 하락하였으며, 그 움직임은 환율의 상승에 직간접적인 영향을 미쳐온 점 등을 고려하면, 채권시장과 금리시장에서 거래되는 상품의 가격과 움직임은 외환시장에도 직간접적인 영향을 주고 있으며, 세 시장 사이엔 상호 유기적이고 보완적인 관계가 있다고 볼 수 있다. 지금까지 채권시장, 금리시장, 그리고 외환시장 사이의 관계와 연관성을 밝히는 연구는 있어왔으나, 과거 많은 환율예측 연구들이 주로 GDP, 경상수지 흑자/적자, 인플레이션 등 거시적인 지표를 기반으로 한 연구에 집중되어 왔으며, 채권시장과 금리시장 지표를 기반으로 인공지능을 활용하여 외환시장의 환율을 예측하는 적극적인 연구는 아직 진행되지 않았다. 본 연구는 채권시장 지표와 금리시장 지표를 기반으로, 비선형데이터 분석에 적합한 인공신경망(Artificial Neural Network) 모델과, 선형데이터 분석에 적합한 로지스틱 회귀분석 (Logistic regression), 그리고 비선형/선형데이터 분석에 활용 가능한 의사결정나무 (Decision Tree)를 각각 사용하여 환율예측 모델을 만들고 그 수익률을 비교하여 어떤 모델이 가장 외환시장 환율 예측을 하는데 적합한지 알려준다. 또한, 본 연구는 주식시장, 금리시장, 오일시장, 그리고 외환시장 환율 등 비선형적 시계열 데이터 분석에 많이 사용되어진 인공신경망 모델이 채권시장과 금리시장 지표를 기반으로 한 외환시장 환율예측 모델에 가장 적합한 방법론을 제공

1) 이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(No. 2021R1A2C1094211).

2) 제1저자, nooklim@yonsei.ac.kr

3) 제2저자, jsh0331@yonsei.ac.kr

4) 제3저자, heesoo@sejong.ac.kr

5) 제4저자, joanoh@yonsei.ac.kr

하고 있다는 것을 증명한다. 채권시장, 금리시장, 그리고 외환시장 간의 단순한 연관성을 밝히는 것을 넘어, 세 시장 간의 거래 신호를 포착하여 적극적인 상관관계를 밝히고 상호 유기적인 움직임을 증명하는 것은 단순히 외환시장 트레이더들에게 새로운 트레이딩 모델을 제시하는 것뿐만 아니라 금융시장 전체의 효율성을 증가시키는데 기여할 것이라 기대한다.

주제어: 지식경영, 인공지능경망, 달러원환율, CCS, KTB

1. 서론

금융시장을 구성하는 여러 시장 중 채권시장, 금리시장, 그리고 외환시장은 각각의 독립적인 시장인 동시에 상호 영향을 주고받는 유기적인 관계에 있다. 예를 들어, 우리나라 채권시장의 대표적 안전자산이자 국내외 투자자들에게 선호되는 국고채와 통안채는 위험 선호 시기에는 안정적인 매수 흐름을 이어가다가 위험 회피상황이 오면 공격적인 매도가 일어나게 되며, 그 공격적인 매도는 외환시장의 달러/원 환율에 상승 신호로 작용하여 달러 매수를 촉발시키게 된다. 우리나라 금리시장의 대표상품인 이자율 스왑 (IRS, Interest Rate Swap)도 기본적으로 이자율이 상승하면 그 나라 통화의 투자매력도를 상승시켜 통화를 절상시키는 기능이 있으며, 반대로 이자율이 하락하면 그 나라 통화의 투자매력도를 감소시켜 통화를 절하시키는 기능이 있다. 또한 통화스왑 (CCS, Cross Currency Swap)의 경우 평소에는 기본적으로 이자율 스왑의 흐름을 따라가다가, 달러 유동성 문제가 부각될 때는 통화스왑 가격이 하락하는 모습을 보이면서 달러/원 환율을 상승시키는 작용을 하다가, 달러 유동성 문제가 해결되면 통화스왑 가격이 상승하면서 달러/원 환율의 하락 요인이 되곤 한다. 이명종 (2020)의 CCS 시장, IRS 시장, KTB 시장, 외환 스왑시장, 외환시장 간 동적 연계성에 관한 연구에서 달러/원 환율의 상승은 CCS 금리를 하락시키고, 스왑 레이트, KTB 금리, IRS

금리의 상승은 CCS 금리를 상승시키는 것으로 확인되면서 금리시장 (CCS & IRS), 채권시장 (KTB), 그리고 외환시장 (달러/원 환율)의 상관관계가 입증되었다.

이렇게 채권시장, 금리시장, 외환시장은 상호 유기적인 관계를 이어가며 상호 영향을 미치고 있음에도 불구하고, 지금까지 많은 외환시장 환율예측과 모델링에 대한 연구는 주로 GDP, 경상수지 흑자/적자, 인플레이션 등 거시경제적인 지표를 독립변수로 사용하여 이루어져 왔으며, 채권시장과 금리시장, 그리고 외환시장 사이의 관계와 연관성을 밝히는 연구는 있어 왔으나, 아직까지 인공지능을 활용하면서 채권시장, 금리시장 지표를 이용해 외환시장의 환율을 예측하는 시도는 되지 않았다.

본 연구에서는 채권시장과 금리시장의 지표를 이용한 외환시장 환율예측 모델을 만드는데 있어 어떤 인공지능 방법론이 가장 적합한 지 밝히려 한다. 채권시장 지표와 금리시장 지표를 기반으로, 비선형데이터 분석에 적합한 인공지능경망(Artificial Neural Network) 모델과, 선형데이터 분석에 적합한 로지스틱 회귀분석 (Logistic regression), 그리고 비선형/선형데이터 분석에 활용 가능한 의사결정나무 (Decision Tree)를 각각 사용하여 환율예측 모델을 만들고 그 수익률을 비교하여 어떤 모델이 가장 외환시장 환율 예측을 하는데 적합한지 알아내는 데에 본 연구의 목적이 있다.

본 논문의 구성은 다음과 같다. 2장 연구배경에서는 외환시장 환율예측에 관한 선행연구를 서술하고,

3장 연구방법에서는 외환시장 환율 예측모델을 만들기 위한 방법론들을 서술하였다. 4장 실증분석에서는 채권시장과 금리시장의 상품가격을 여러 분석 방법론을 활용하여 분석한 내용을 서술하였고, 5장 결론에서는 본 연구 실험의 결과와 그 의의, 그리고 향후 연구 주제를 제시한다.

2. 연구 배경

외환시장 환율은 전형적인 시계열 데이터이면서, 날씨와 주식시장 데이터처럼 비 선형적인 모습을 보인다. Grassberger and Procaccia (2004)이 밝힌 것처럼 외환시장 환율과 같은 시계열 적인 데이터는 정리되어 있지 않고 임의적으로 보이지만, 그 안에서 상호 연결 적이고 일정한 패턴이 보이는 카오스적 행동 (Chaotic Behavior)을 보인다 (Wang et al., 2013). 카오스적 행동을 보이는 비선형 데이터를 분석하기 위해서는 여러 인공지능 방법론 중 어떤 방법론이 적합한지를 밝혀내는 것이 중요하다. <표 1>에서 보여지는

것처럼 선행연구를 통해 인공신경망 (Artificial Neural Networks)은 주식시장의 주가예측에 사용 (김현호, 오경주 2012) 되어 온 것뿐만 아니라 이자율 시장 예측 (Oh and Han, 2000; Lahmiri, 2016), 유가 예측 (Lahmiri, 2016), 그리고 외환시장 환율 예측 (Huang et al., 2004; Lahmiri, 2017; Evans et al., 2013; Stoke and Abou.Zaid, 2012)에도 사용되어 온 것을 알 수 있었으며, 다양한 분야에서 머신러닝 방법론이 활용되어 왔다 (윤상혁 등 2019, 박주영, 윤현식 2019). 그 이외의 연구들도 인공신경망이 다른 인공지능 방법론 보다 비 선형적이고 시계열 적인 외환시장 환율 데이터를 분석하는데 적합하다는 것을 입증하였다.

본 연구에서는 선행연구를 통해 입증된 인공신경망의 비선형적이고 시계열적인 데이터에 대한 적합성이 채권시장과 금리시장의 지표를 활용하여 외환시장을 환율을 예측하는데 있어서도 그 적합성이 적용되는지를 확인해 보려 한다.

또한, 환율을 목적변수로 하고 어떤 독립변수를 사용할 것인지에 대한 결정도 올바른 방법론을 논하기

<표 1> 비선형적(Nonlinear)이고 시계열(Time Series)적인 데이터연구에 인공신경망이 적합하다는 것을 입증한 선행연구 비교 정리

| Article | Contents summary |
|---|---|
| Trippi, R. R.; Turban, E. 1992. | 인공신경망(ANN)을 이용하여 재무와 투자의 실제 거래에서 성과를 높이는 실험. |
| Oh, K. J.; Han, I. 2000. | 이자율 예측을 위하여 인공신경망(ANN) 활용하는 연구 |
| Kim, T. Y.; Oh, K. J.; Kim, C.; Do, J. D. 2004. | 시계열 데이터 분석에 인공신경망(ANN) 활용하는 연구 |
| Huang, W.; Lai, K. K.; Nakamori, Y.; Wang, S. 2004. | 인공신경망(ANN)을 이용하여 외환시장 환율 예측 |
| Stokes, A.; Abou-Zaid, A. S. 2012. | 트레이더의 관점에서 인공신경망(ANN)을 이용하여 외환시장 환율 예측 |
| Evans, C.; Pappas, K.; Xhafa, F. 2013. | Intra-day 외환거래를 위한 Algo-trading model 구축을 위해 인공신경망(ANN)과 Genetic Algorithms(GA) 활용하는 연구 |
| Lahmiri, S. 2016. | Hybrid Feedforward 신경망을 기반으로 한 이자율 변동 예측 |
| Lahmiri, S. 2016. | 경제 및 금융 시계열의 분석 및 예측을 위한 Variational mode decomposition 접근 방식에 대한 연구 |
| Lahmiri, S. 2017. | 환율시장의 역사적 변동성 모델링 및 예측하면서 인공신경망(ANN)이 가장 효율적인 방법론임을 입증 |

전에 선행되어야 할 사안이다. 앞에서 기술한 것처럼 지금까지 많은 외환시장 환율예측과 모델링에 대한 연구는 주로 GDP, 경상수지 흑자/적자, 인플레이션 등 거시 경제적인 지표를 독립변수로 사용하여 이루어져 왔다. Cheung & Chinn (1999)는 National Bureau of Economic Research에서 미국 외환 트레이더 들과의 Survey를 통해 거시경제적 변수들에 대한 뉴스는 즉시 외환시장에 반영된다는 것과, 개별적 거시경제적 변수들의 중요성이 증가하고 있다는 것, 그리고 경제적인 펀더멘털이 점점 환율을 결정하는데 있어 중요해지고 있다는 것을 발표하였다. Kočenda & Poghosyan (2009)는 새로운 EU 회원국의 외환 위험 및 거시 경제 결정 요인 문제에 대해 연구하였으며, Mun K.C. (2012)는 미국과 일본의 데이터를 이용하여 거시경제적 충격에 대한 주식시장과 외환시장의 공동 반응에 대한 연구를 진행하였다. Omrane & Savaser (2016)은 거시경제적 데이터와 뉴스가 외환시장에 미치는 영향을 연구하였으며, Kris Boudt et al.(2019)는 거시경제적인 뉴스가 환율에 미치는 영향을 연구하였다. 그리고, Fabian U.Fuchs (2020)는 수출입 관련 외환위험 헤징을 위한 환율 예측에 있어서 거시경제적 지표들을 사용한 연구를 수행하였다.

하지만, 본 연구에서는 기존의 거시경제적인 지표와 결정변수를 사용하는 대신 채권시장과 금리시장의 상품가격이 외환시장의 환율과 밀접한 정보 교류와 상호작용을 하고 있다는 사실을 토대로, 채권시장, 금리시장 상품 가격을 새로운 독립변수로 하여, 목적변수인 달러/원 환율을 예측하고자 한다. 본 연구를 통해 금리시장과 채권시장의 지표들이 외환시장의 선행 지표가 될 수 있음을 입증하고, 금융시장 속 서로 각자 다른 기능을 가진 외환시장, 금리시장, 채권시장이 서로 유기적이고 상호 보완적인 관계에서 움직이고 있다는 것을 증명하려 한다.

3. 연구방법

외환시장 환율 데이터를 분석하기 위하여 의사결정나무, 로지스틱 회귀분석, 그리고 인공신경망의 3가지 방법론을 활용하였다.

3.1. 로지스틱 회귀분석 (Logistic regression)

인공지능 방법론 중 로지스틱 회귀분석은 종속변수가 이분형 데이터일 때 주로 쓰이는 통계적 방법론이다. 따라서 선행연구 들에서는 주가의 상승하락을 예측하는 등의 이분형 예측모델을 구축할 때 많이 사용되었다 (이현수 등 2019; 조득환 등 2020). 로지스틱 회귀분석은 회귀 모델이기 때문에 비교적 선형성을 띄는 데이터에게 적합한 방법론이다.

본 연구의 실증분석을 위해 IBM SPSS Statistics 25를 사용했다. 로지스틱 회귀분석은 입력한 변수를 모두 사용하도록 설정하여 실증분석을 진행하였으며, 학습 (training) 데이터와 검증 (testing) 데이터는 의사결정나무와 동일하게 각각 1년 6개월과 6개월로 설정하였다.

3.2. 의사결정나무 (Decision Tree)

인공지능 방법론 중 의사결정나무는 데이터들을 이용하여 분류모형을 만드는 기법이다. 분류모형이 나뉘어가지 형태를 보이기 때문에 의사결정나무라고 불린다 (김현호, 오경주 2012). 의사결정나무는 종속변수를 가장 잘 설명할 수 있는 독립변수를 선정하고, 그 변수를 기준으로 종속변수를 결정하기위한 하위 가지를 설정한다. 그리고 그 다음 종속변수를 잘 설명하는 독립변수를 하위 가지로 추가하는 방식으로 의사결정나무는 구축된다.

본 연구의 실증분석을 위해 IBM SPSS Statistics 25

를 사용했다. 다양한 의사결정나무의 성장방법 중 CHAID 방법을 활용하였다. 최대 나무 깊이는 3으로 설정하였으며, 부모 노드는 최소 케이스 수를 100으로, 자식 노드는 최소 케이스 수를 50으로 설정하였다. 데이터의 경우 학습 (training) 데이터는 1년 6개월로 설정하였고, 검증 (testing) 데이터는 6개월로 설정하였다.

3.3. 인공신경망 (Artificial neural network)

인공지능 방법론 중 인공신경망은 종속변수를 구하기 위한 독립변수들의 구조가 신경망 구조를 띠는 기법이다 (오경주 등 2011, 김홍곤 등 2017). 인공신경망의 구조는 독립변수와 종속변수 사이에 여러 개의 노드가 존재하고, 독립변수와 노드 간, 그리고 노드들과 종속변수 간에 가중치가 각각 존재하기 때문에, 독립변수와 종속변수 간의 모델을 설명하기 어려운 방법론이다.

본 연구의 실증분석을 위해 IBM SPSS Statistics 25를 사용했다. 인공신경망의 경우는 초기 값을 고정해 주지 않으면 매번 다른 결과 값이 도출되기 때문에, 결과의 일관성을 위해 초기 값을 50으로 고정해주었다. 공변량의 조정은 표준화 방식을 택하였고, 신경망 설계는 은닉층에서의 노드 수를 최소 1에서 최대 50 중 자동으로 설정하도록 하였다. 인공신경망의 경우 검증 (validation) 데이터도 필요하기 때문에, 의사결정나무 방법론과 로지스틱 회귀분석 방법론에서의 학습 (training) 데이터를 학습 데이터와 검증 데이터로 나누

어 주었다. 따라서 학습 (training) 데이터는 1년, 검증 (validation) 데이터는 6개월, 검증 (testing) 데이터는 6개월로 설정하였다.

4. 실증 분석

실증 분석을 위해 <표 2>과 같이 달러/원 환율, 1Y 원화 IRS 금리와 1Y 원화 CCS 금리, 10Y 원화 IRS 금리와 10Y KTB 수익률, 그리고 10Y 본드 스왑 스프레드 (IRS-KTB)를 활용했다. 사용된 데이터는 모두 일별 종가를 사용하였다.

사용한 데이터의 표본기간은 2008년 1월부터 2020년 12월까지이다. 이는 본 연구에서 사용된 목적변수와 독립변수들의 상관관계가 2008년 위기상황에서도 효과적으로 작동하는지를 확인하기 위함이며, 이후 2009년부터 최근의 2020년 말까지의 금융시장에서도 효과적으로 그 상관관계가 유지되는 것을 확인하기 위함이다. 2008년의 데이터는 2009년 하반기 데이터 검증(Testing)을 위한 학습(Training)데이터로 한번만 쓰였고, 나머지 년도 데이터는 슬라이딩 윈도우 방식으로 매 1년씩 표본기간을 다르게 하여 실험결과가 동일 한지 확인하는 실험을 진행하였다.

4.1. 변수 선정

4.1.1. 목적변수

목적변수인 달러/원 환율 종가 데이터는 금융정보

<표 2> 실증 분석에 사용된 데이터

| Data | Period (yyyy/mm/dd) | Source |
|----------------------------------|-----------------------|----------------|
| USDKRW exchange rates | 2008/01/01–2020/12/31 | Yonhap Infomax |
| 1Y KRW IRS rates | 2008/01/01–2020/12/31 | Bloomberg |
| 1Y KRW CCS rates | 2008/01/01–2020/12/31 | Bloomberg |
| 10Y KRW IRS rates | 2008/01/01–2020/12/31 | Bloomberg |
| 10Y KTB yields | 2008/01/01–2020/12/31 | Bloomberg |
| 10Y Bond Swap Spread (IRS – KTB) | 2008/01/01–2020/12/31 | Bloomberg |

전문 업체 이자 연합뉴스의 자회사인 연합 인포맥스에
서 수집하였다. 연합 인포맥스는 매일 그날의 달러/원
환율의 시가/고가/저가/종가 데이터를 서울 외국환중
개 (SMBS; Seoul Money Brokerage Services)에서 받아
서 정보 단말기를 통해 구독자에게 제공한다. 국내 달
러/원 스팟 시장의 영업시간은 서울시간 오전 9시부터
오후 3시 30분까지이다. 그러므로 달러/원 환율의 종가
는 오후 3시 30분에 서울 외국환중개 로이터 페이지에
고시되고, 동시에 연합 인포맥스 단말기에 고시된다.

4.1.2. 독립변수

(1) 금리시장 지표

금리시장의 독립변수로는 유동성이 가장 좋은 1Y
원화 IRS 금리와 1Y 원화 CCS 금리를 사용했다.

원화 IRS (Interest Rate Swap) 또는 원화 이자율 스
왑은 금리변동위험 헤지의 목적으로 거래당사자 간에
원금 교환 없이 3개월마다 변동금리와 고정금리를 교
환하는 거래를 말한다. 여기서의 변동금리는 91일물
CD 금리를 말하며, 고정금리는 IRS 거래금리를 말한
다. 통상 100억 원 단위로 거래를 하며 만기 1년에서
5년 거래가 주를 이루지만, 만기 10년까지의 거래도
시장조성에 큰 문제없이 이루어지고 있다. 1년 IRS 금
리와 같은 단기 이자율 스왑 금리는 한국은행 정책금
리 변동에 민감하게 움직이는 특성이 있는데, 이덕호
(2006)의 WTO 환경 하에서 국내 환율결정요인에 대
한 실증분석 연구와 홍유정, 하홍열 (2019)의 금융자
산시장에서의 외국인투자자와 환율에 관한 연구에서 밝
혀진 IRS 금리와 환율의 상관관계를 토대로, 현지통
화의 이자율이 높아지면 해당통화의 투자매력도가 상
승하여 달러에 대한 해당통화의 절상 (달러/원 환율하
락)을 야기시키며, 현지통화의 이자율이 낮아지면 해
당통화의 투자매력도가 하락하여 달러에 대한 해당통
화의 절하 (달러/원 환율 상승)를 이끈다는 것을 알 수

있다. 그리고 이현재 (1997)의 원화의 대미 환율결정
에 관한 실증분석에서도 양국간의 이자율 차이는 환
율의 평가 절상 또는 절하를 가져온다고 밝혀 IRS 금
리와 환율과의 상관관계가 있다는 것을 알 수 있다.

원화 CCS (Cross Currency Swap) 또는 원화 통화 스
왑은 거래당사자 간에 서로 다른 통화를 주고받고 일
정기간 후 원금을 다시 주고받기로 하는 약정을 말하
며, 계약기간 중 이자를 매 6개월 마다 주고받고 만기
시점에 처음 원금을 교환했을 때 적용했던 환율로 다
시 원금을 주고받는 거래를 말한다. 유동성은 외환 스
왑과 만기가 겹치는 만기 1년 거래가 가장 높고, 2년
부터 10년까지의 유동성은 이자율 스왑에 비해 현저
히 낮은 편이다.

김홍원 (2008)의 최근 환율변동이 한국의 국제수지
에 미치는 영향에 관한 연구에서 저자는 글로벌 시장
에서 국내은행들의 외화차입 여건이 급속하게 악화되
면 외환시장에서의 달러화에 대한 수요가 증가하고,
그에 따라 통화 스왑 (CCS) 금리가 하락하면 달러/원
환율의 상승을 전인한다고 밝히며 통화스왑(CCS)과
달러/원 환율과의 상관관계를 입증하였다. 이렇듯 일
반적으로 우리나라 시장에서 달러조달의 문제가 생길
때 달러를 조달할 수 있는 통화스왑 Receive 수요가
증가해 통화 스왑 금리가 하락하며, 그런 통화 스왑
가격의 움직임은 외환시장에서 달러 매수의 신호로
인식돼 많은 경우 달러/원 환율이 상승하는 모습을 보
여 왔다. 이후 달러조달의 문제가 해결되었을 경우 통
화 스왑 Pay 수요가 증가해 통화 스왑 금리가 상승하
며, 그런 통화 스왑 가격의 움직임은 외환시장에서 달
러 매도의 신호로 인식돼 많은 경우 달러/원 환율이
하락하는 모습을 보여 왔다.

(2) 채권시장 지표

추가적인 독립변수로는 채권시장의 10Y KTB 수익

를 사용하였다. 국고채 수익률은 평소에는 수요와 공급의 법칙에 따라 움직이다가 위험 회피 현상이 오면 투자자는 국고채 매도를 통해 자산 보유를 줄이게 되며, 그러한 국고채 가격의 하락 (국고채 수익률 상승)은 외환시장에서 달러 매수의 신호로 인식돼 달러/원 환율이 상승하는 모습을 보인다. 이후 시장이 안정되면 다시 자산을 되 사려는 투자자들의 국고채 매수 움직임으로 인해 국고채 가격은 상승 (국고채 수익률 하락)하게 되며, 이는 외환시장에서 달러 매도의 신호로 인식돼 달러/원 환율이 하락하는 모습을 보이게 된다.

(3) 금리시장과 채권시장의 동시지표: 본드 스왑 스프레드

채권시장의 국고채 수익률과 외환시장의 달러/원 환율 간의 일정 수준의 상관관계가 있다고 하더라도, 기본적으로 국고채 수익률은 IRS 금리와 움직임을 같이 하며 IRS 금리에 수렴하거나 IRS 금리를 국고채 수익률에 수렴시키는 관계를 가지고 있다. 그러므로 본 실험에서 환율을 예측하는데 있어 금리시장/채권시장 독립변수로 사용한 IRS와 KTB 금리에 더해, 좀 더 외환시장의 달러/원 환율과 상관관계가 높은 변수인 본드 스왑 스프레드 가격 (IRS 금리에서 KTB 수익률을 뺀 가격)을 제5의 독립변수로 사용하려 한다. 본드 스왑 스프레드는 IRS 금리와 KTB 수익률의 차이를 말한다. 여기서 IRS 금리란 앞에서 서술한 대로 변동금리와 교환되는 고정금리를 말하는데, 이때 변동금리는 91일물 CD금리를 말하며, CD 금리는 은행의 신용이 반영된 금리이다. 그러므로 CD금리와 교환되는 IRS금리도 마찬가지로 은행의 신용이 반영된 금리인 것이 된다. KTB 수익률은 정부가 발행한 채권으로 정부의 신용이 반영된 금리이다. 이론적으로는 정부의 신용이 은행보다 높으니 국고채 수익률이 IRS금리보다 낮은 것이 일반적이나, 우리나라의 경우는 정부의

활발한 재정정책으로 국고채 발행이 수요보다 많은 점, 그리고 은행권의 변동금리 대출이 고정금리 대출보다 많아 은행권의 IRS 리시브 수요가 많고, 보험사들의 듀레이션 관리를 위한 IRS 리시브 수요가 많은 이유로 대개 국고채 수익률이 IRS 금리보다 높게 형성되어 있다. 즉, 우리나라의 본드 스왑 스프레드 (IRS 금리 - KTB 수익률)는 대개 음(-)의 상태로 지속되어 왔다. 만약 시장에 위험회피 현상이 나타나 투자자들이 KTB 매도를 단행하게 되면 국고채 수익률은 IRS 금리보다 더 빨리 상승하게 되며, 음(-)의 본드 스왑 스프레드는 더욱 확대 (Bond Swap Spread Widening) 되게 된다. 이 경우 외환시장의 달러/원 환율은 본드 스왑 스프레드의 확대를 달러 매수의 신호로 여기게 되어 달러/원 환율은 상승하게 되며, 이 후 시장이 안정되어 투자자들의 KTB 매수 심리가 회복되면 IRS 금리보다 KTB 수익률은 더 빨리 하락하게 되고, 이는 본드 스왑 스프레드의 축소 (Bond Swap Spread Tightening)로 이어지며, 외환시장은 이를 달러 매도 신호로 해석해 달러/원 환율은 하락하게 된다.

4.2. 인공지능 방법론 간 Hit Ratio 비교

유의미한 예측모델을 만들기 위한 방법론으로 인공신경망 (ANN), 로지스틱 회귀분석 (LR), 의사결정나무 (DT)를 사용하여 진행하였고, 이에 대한 Hit Ratio를 확인하였다. Hit Ratio는 예측모델의 성능을 판단할 때 자주 사용되는 지표이지만, 비 선형적이고 시계열적인 데이터를 다루는 예측모델에는 단순 적용하기에는 여러 가지 제약점이 있다. 이는 실제 트레이딩에 있어 높은 Hit Ratio를 가진 트레이더가 반드시 실제 높은 수익을 올리지는 않으며, Hit Ratio는 낮아도 리스크 관리 원칙 아래 시장의 큰 흐름에 적절히 대응해 거래하는 트레이더가 때로는 더 큰 수익을 올리는 경

우가 많다는 점과 맥을 같이 한다. 그러므로 본 연구에서는 Hit Ratio의 절대 레벨평가 보다는, 비 선형적이고 시계열 적인 외환시장, 채권시장, 금리시장의 데이터를 다루는데 있어 어떤 인공지능 방법론이 가장 적합한지를 찾는데 Hit Ratio를 사용하려 한다. <표 3>에서 보이는 대로 ANN 방법론이 51%에 가까운 Hit Ratio를 보이면서 다른 방법론의 Hit Ratio와 비교하여 가장 좋은 성능을 보여주었다. 다음 장에서는 각 인공지능 방법론으로 만들어진 트레이딩 모델로 트레이딩 시뮬레이션을 수행해 보고 각 모델 간의 수익률을 비교해 보려 한다.

4.3. 예측모델 실험

인공지능 방법론인 ANN, LR, DT를 활용하여 달러/원 환율의 일별 예측 값을 얻어내고, 그 예측 값을 실제 과거 데이터에 적용해서 거래 수익률을 구하는 트레이딩 모델 시뮬레이션을 수행하였다. 트레이딩 모델은 매일 오후 3시 30분 그날의 달러/원 스팟 시장이 마감된 후 그날의 1Y IRS, 1Y CCS, 10Y IRS, 10Y KTB, 그리고 10Y IRS-KTB 종가를 가지고, ANN, LR, DT의 3가지 인공지능 방법론을 통해 달러/원 환율을 매입할 것 인지 또는 매도할 것인지에 대한 거래신호를 만든다. 그런 후 2009년 1월부터 2020년 12월까지

<표 3> Trading model의 Hit Ratio

| Hit ratio | ANN | LR | DT |
|-----------|--------|--------|--------|
| Set 1 | 55.81% | 44.19% | 43.41% |
| Set 2 | 47.97% | 47.97% | 47.15% |
| Set 3 | 61.72% | 57.81% | 64.84% |
| Set 4 | 48.36% | 57.38% | 57.38% |
| Set 5 | 44.80% | 44.80% | 44.80% |
| Set 6 | 50.41% | 49.59% | 49.59% |
| Set 7 | 60.80% | 53.60% | 60.00% |
| Set 8 | 47.97% | 47.97% | 47.15% |
| Set 9 | 58.87% | 41.13% | 58.87% |
| Set 10 | 56.20% | 56.20% | 56.20% |
| Set 11 | 50.00% | 52.42% | 50.00% |
| Set 12 | 45.90% | 54.10% | 45.90% |
| Set 13 | 53.17% | 51.59% | 48.41% |
| Set 14 | 47.93% | 47.93% | 45.45% |
| Set 15 | 45.60% | 44.80% | 54.40% |
| Set 16 | 50.82% | 50.82% | 50.82% |
| Set 17 | 56.20% | 56.20% | 38.02% |
| Set 18 | 47.11% | 47.11% | 47.11% |
| Set 19 | 52.03% | 52.03% | 52.03% |
| Set 20 | 47.90% | 47.90% | 47.90% |
| Set 21 | 48.76% | 47.93% | 52.07% |
| Set 22 | 54.47% | 50.41% | 56.91% |
| Set 23 | 39.34% | 39.34% | 39.34% |
| Average | 50.96% | 49.70% | 50.34% |

실제 달러/원 환율 데이터에 적용해 해당 트레이딩 모델의 거래 수익을 계산한다. 트레이딩 시뮬레이션을 수행하는데 있어서 다음과 같은 트레이딩 룰을 적용하였다.

1 단계. 만약 인공지능 모델의 예측 값이 testing 기간 동안 1이 나오면 매수신호로 달러/원을 매수한다. 만약 0일 경우 매도 신호로 달러/원을 매도한다.

2 단계. 달러/원 매수, 매도의 시점과 가격은 다음날의 달러/원 스왑 시가를 사용한다.

3 단계. 트레이딩 모델의 수익을 계산 시, 포지션을 유지하고 있는 기간 동안에는 적절한 스왑 포인트(Swap point)를 적용하여 거래 수익계산을 좀 더 정확하게 한다. 스왑 포인트 계산을 위하여 사용되어진 원화 이자율은 한국은행 기준금리이며, 달러 이자율은 FOMC's Target Federal Funds rate이다. (Federal Reserve System)

스왑 포인트는 다음과 같은 공식으로 구한다.

$$\text{스왑 포인트} = \text{스왑 가격} \left(\frac{(1 + \text{원화이자율})}{(1 + \text{달러이자율})} - 1 \right)$$

4 단계. 달러/원 포지션은 최고 5개까지로 제한한다. 거시경제적 영향을 많이 받는 환율데이터 특성상 장기간 같은 방향의 신호가 나오는 경우가 많은데 이 경우엔 영원히 포지션을 누적시키는 것은 현실적이지 않으므로 1주일 (5 trading days)로 포지션 누적을 제한한다.

5 단계. 트레이딩 수익률을 계산하는데 사용되는 투자금액은 당 해의 평균 환율로 한다. 포지션이 누적되는 동안의 투자금액은 원화금리와 달러금리의 차이인 스왑 포인트로 계산되어 총 누적 수익/손실 금액에서 가감하는 형태로 반영한다.

위의 조건으로 트레이딩 시뮬레이션을 해본 결과, <표 4>에서와 같이 ANN의 수익률이 3.791%로 LR, DT에 비해 더 나은 모습을 보여주었다. ANN을 활용해 채권시장, 금리시장 지표를 독립변수로 만든 달러/원 트레이딩 모델의 수익률 3.791%는 동 기간 안전자

<표 4> 실증 분석 결과

| Year | Amt Invested | ANN | | LR | | DT | |
|----------------|--------------|-----------|-------------------|-----------|-------------------|-----------|-------------------|
| | | P/L | Annualized Return | P/L | Annualized Return | P/L | Annualized Return |
| 2009 | 1204.31 | 113 | 9.4% | 66 | 5.5% | -42 | -3.5% |
| 2010 | 1156.73 | 491 | 42.4% | -1,053 | -91.0% | -953 | -82.4% |
| 2011 | 1108.22 | 289 | 26.0% | 722 | 65.1% | 775 | 69.9% |
| 2012 | 1126.49 | -46 | -4.0% | -531 | -47.1% | -478 | -42.4% |
| 2013 | 1095.08 | -6 | -0.5% | -226 | -20.6% | 29 | 2.6% |
| 2014 | 1053.45 | 721 | 68.4% | 233 | 22.1% | 721 | 68.4% |
| 2015 | 1131.78 | -469 | -41.5% | 294 | 26.0% | -563 | -49.8% |
| 2016 | 1160.24 | -92 | -7.9% | 166 | 14.3% | -518 | -44.6% |
| 2017 | 1130.02 | -602 | -53.3% | -527 | -46.7% | -39 | -3.5% |
| 2018 | 1100.61 | 68 | 6.2% | -47 | -4.3% | -747 | -67.9% |
| 2019 | 1165.88 | -279 | -23.9% | -310 | -26.6% | -170 | -14.5% |
| 2020 | 1180.39 | 285 | 24.2% | 418 | 35.4% | 103 | 8.7% |
| Position Limit | | Total P/L | Average Return | Total P/L | Average Return | Total P/L | Average Return |
| 5 | | 473.32 | 3.791% | -793.87 | -5.647% | -1882.64 | -13.243% |

산 수익률인 만기 1년의 통안채, 만기 2년의 통안채, 만기 3년의 국고채, 그리고 만기 10년의 국고채의 수익률 (<표 5>)을 상회하며, 이는 달러/원 환율 트레이딩 예측모델에는 인공지능 방법론 중 ANN이 적합하다는 것을 보여준다.

보다 실질적인 결과 비교를 위해 <표 4>에서 제시한 결과에서 거래비용을 차감하였다. 거래비용은 거

래횟수에 0.5% (0.005)를 곱하여서 P/L에서 차감해주었다. 본 연구의 실증분석 기간동안 (2009-2020)의 평균 거래회수는 <표 6>과 같이 20회 정도이며, 총 거래비용은 1.205로 나타났다. 이 거래비용을 고려한 모델의 연 환산 수익률은 3.782%를 나타냈다.

제안모델의 성과를 비교하기위해 <표 7>과 같이 샤프비율을 비교해보았다. 제안 모델의 경우 MSB, KTB

<표 5> MSB와 KTB의 수익률 (2009-2020)

| Year | 1Y MSB | 2Y MSB | 3Y KTB | 10Y KTB |
|---------|--------|--------|--------|---------|
| 2009 | 2.98% | 3.84% | 4.05% | 5.17% |
| 2010 | 3.03% | 3.66% | 3.71% | 4.77% |
| 2011 | 3.55% | 3.71% | 3.62% | 4.20% |
| 2012 | 3.12% | 3.16% | 3.13% | 3.44% |
| 2013 | 2.66% | 2.75% | 2.79% | 3.28% |
| 2014 | 2.45% | 2.53% | 2.59% | 3.19% |
| 2015 | 1.70% | 1.76% | 1.79% | 2.30% |
| 2016 | 1.44% | 1.45% | 1.44% | 1.75% |
| 2017 | 1.55% | 1.73% | 1.80% | 2.28% |
| 2018 | 1.86% | 2.05% | 2.10% | 2.50% |
| 2019 | 1.54% | 1.55% | 1.53% | 1.70% |
| 2020 | 0.96% | 1.05% | 1.07% | 1.50% |
| Average | 2.24% | 2.44% | 2.47% | 3.01% |

<표 6> 거래비용을 고려한 결과

| Year | Amt Invested | P/L | Annualized Return | # of TXN | fee | P/L-fee | Annualized -fee Return |
|----------------|--------------|-----------|-------------------|-------------|-----------|---------------|------------------------|
| 2009 | 1204.31 | 113 | 9.4% | 16 | 0.08 | 112.90 | 9.37% |
| 2010 | 1156.73 | 491 | 42.4% | 14 | 0.07 | 490.81 | 42.43% |
| 2011 | 1108.22 | 289 | 26.0% | 36 | 0.18 | 288.46 | 26.03% |
| 2012 | 1126.49 | -46 | -4.0% | 21 | 0.11 | -45.72 | -4.06% |
| 2013 | 1095.08 | -6 | -0.5% | 2 | 0.01 | -5.79 | -0.53% |
| 2014 | 1053.45 | 721 | 68.4% | 2 | 0.01 | 720.52 | 68.40% |
| 2015 | 1131.78 | -469 | -41.5% | 19 | 0.10 | -469.56 | -41.49% |
| 2016 | 1160.24 | -92 | -7.9% | 51 | 0.26 | -92.14 | -7.94% |
| 2017 | 1130.02 | -602 | -53.3% | 14 | 0.07 | -601.86 | -53.26% |
| 2018 | 1100.61 | 68 | 6.2% | 10 | 0.05 | 68.12 | 6.19% |
| 2019 | 1165.88 | -279 | -23.9% | 15 | 0.08 | -278.59 | -23.90% |
| 2020 | 1180.39 | 285 | 24.2% | 41 | 0.21 | 284.97 | 24.14% |
| Position Limit | | Total P/L | Average Return | Average TXN | Total fee | Total P/L-fee | Average (-fee) Return |
| 5 | | 473.32 | 3.791% | 20 | 1.205 | 472.12 | 3.782% |

〈표 7〉 샤프비율 비교

| | Average Return | Stdev | Sharpe Ratio |
|----------------|----------------|--------|--------------|
| Proposed Model | 3.782% | 0.3279 | 0.1154 |
| 1Y MSB | 2.236% | 0.0079 | 2.8149 |
| 2Y MSB | 2.435% | 0.0094 | 2.5989 |
| 3Y KTB | 2.469% | 0.0095 | 2.5960 |
| 10Y KTB | 3.203% | 0.0117 | 2.5751 |

보다 연평균 수익률이 높았지만, 변동성이 크기 때문에 샤프비율이 비교적 낮게 나온 것을 확인할 수 있다. 안정성 측면에서는 MSB와 KTB가 우수하지만, 공격적 투자를 감행해야 하는 트레이더의 입장에서는 안정성을 양보하면서 수익을 극대화하는 투자가 필요한 상황이다. 따라서 본 제안모델은 이러한 공격적인 투자자들에게 적합한 모델임을 확인하였다.

5. 결론

달러/원 환율 예측연구에 있어서 거시경제적 지표를 사용하는 연구 이외에 금리시장이나 채권시장의 지표를 사용하여 인공지능 기법을 활용한 연구는 많이 부족한 상황이다. 본 연구에서는 목적변수인 외환시장 환율을 예측하는데 있어서 금리시장의 지표인 이자율 스왑 (IRS)과 통화스왑 (CCS) 지표를 독립변수로 사용하였고, 채권시장의 지표인 국고채 수익률을, 그리고 금리와 채권시장의 공통지표인 본드 스왑 스프레드 (Bond Swap Spread)를 독립변수로 사용하였다는 점에서 의미가 있다. 더 나아가 본 연구는 인공지능 방법론에 있어서 시계열 적인 외환시장 환율을 예측하는 경우엔 선형적 데이터 분석에 많이 사용되어 온 로지스틱 회귀분석 (Logistic Regression)이나 비선형적/선형적 데이터 모두에서 사용되어 졌던 의사결정나무 (Decision Tree)를 활용하는 것 보다는 비선형적 데이터 분석에 적합한 인공신경망(ANN, Artificial

Neural Network)이 활용하는 것이 적합하다는 것을 보여주었다. 본 연구는 실제로 달러/원 환율을 거래하는 외환 트레이더에게는 금리시장과 채권시장의 지표들이 외환시장의 선행지표가 될 수 있음을 제안하였으며, 이는 금융시장 속 서로 각자 다른 기능을 가진 외환시장, 금리시장, 채권시장이 서로 유기적이고 상호보완적인 관계에서 움직이고 있다는 것을 증명하였다.

본 연구에서 사용된 금리시장, 채권시장의 변수들은 분명 외환시장 환율과 상관관계가 있는 변수들이지만, 해당 변수를 사용해 ANN을 활용하여 만든 트레이딩 모델의 수익률이 안전자산인 통안채와 국고채 수익률을 조금 넘어서는 수준의 수익률이라는 점은 향후 연구에서는 좀 더 개선해야할 부분이라고 생각한다. 이를 위해 본 연구에서 얻어진 연구 성과, 즉, 환율예측에는 인공지능 방법론 중 ANN 사용이 적합하다는 사실에 더해서, 본 연구에서 사용되어진 금리시장, 채권시장의 독립변수 이외의 다른 독립변수를 찾아서 ANN을 통해 만든 달러/원 환율 트레이딩 모델의 수익률을 좀 더 높여보려 한다. 또한 안전자산인 MSB와 KTB보다 샤프비율을 높인 모델에 대한 연구도 진행해 보고자 한다.

〈참고문헌〉

[국내 문헌]

- 곽주영, 윤현식 (2019). 머신러닝을 활용한 TV 오디션 프로그램의 우승자 예측 모형 개발: 프로듀스 X 101 프로그램을 중심으로. **지식경영연구**, 20(3), 155-171.
- 김진호, 김세완 (2008). 역전된 스왑 금리와 차익거래 지속의 이례현상 분석. *Working Paper*, 이화여자대학교.
- 김현호, 오경주 (2012). 리프집합을 활용한 캔들스틱 트레이딩 최적화 전략. **한국데이터정보과학회지**, 23(5), 881-893.
- 김홍곤, 김소담, 김희웅 (2018). 핀테크 기반 주식투자 최적화 모델 구축 사례 연구: 기관투자자 대상. **지식경영연구**, 19(1), 97-118.
- 김홍원 (2008). 최근 환율변동이 한국의 국제수지에 미치는 영향에 관한 연구. **관세학회지**, 9(3), 385-405.
- 오경주, 김태윤, 정기웅, 김치호 (2011). 선형 및 신경망 자기회귀모형을 이용한 주식시장불안정성지수 개발. **한국데이터정보과학회지**, 22(2), 335-351.
- 윤상혁, 이소현, 김희웅 (2019). 머신러닝 기반의 디지털 방송 프로그램 유형 분류 및 활용 방안 연구. **지식경영연구**, 20(3), 119-137.
- 윤재형 (2012). 금리, 환율, 주식수익률의 상호의존성 분석: 다변량 VAR-EGARCH 모델을 중심으로. **산업경제연구**, 25(4), 2485-503.
- 이근영 (2009). 외환, 주식, 화폐, 채권시장의 연계성 분석. **한국경제연구**, 25, 97-133.
- 이대기, 유병학 (2009). 한국금융시장의 국내외 연관성 분석. *East Asian Economic Review*, 13(2), 145-72.
- 이덕호 (2006). WTO 환경 하에서 국내 환율결정요인에 대한 실증분석. **통상정보연구**, 8(4), 159-175.
- 이명중 (2020). CRS 시장, IRS 시장, KTB 시장, 외환스왑시장, 외환시장 간 동적연계성에 대한 연구. **금융공학연구**, 19(2), 121-51.
- 이현수, 정승환, 오경주 (2019). 한국 NPL 시장 수익률 예측에 관한 연구. **지능정보연구**, 25(2), 123-139.
- 이현재 (1997). 원화의 대미 환율결정에 관한 실증분석: 공적 분추정법에 의한 접근. **국제경제연구**, 3(3), 129-151.
- 조득환, 류호선, 정승환, 오경주 (2020). 인공지능 (AI)을 활용한 공모주 투자여부 및 기준 수익률 달성 여부 예측 모델.

한국데이터정보과학회지, 31(3), 579-590.

- 지호준, 김상환 (2001). 외환, 주식, 채권시장의 상호 관련성-한국, 일본의 비교. **재무관리연구**, 18(2), 169-191.
- 홍유정, 하홍열 (2019). 금융자산시장에서의 외국인투자자와 환율에 관한 연구: 한국의 채권이자율과 주가수익률을 중심으로. **사회과학연구**, 26(1), 39-60.
- 홍정호, 조혜원 (2010). 환율, 금리, 주가사이의 동적연관성 연구. *Asia-Pacific Journal of Business & Commerce*, 2(1), 1-21.

[국외 문헌]

- Boudt, K., Neely, C. J., Sercu, P., & Wauters, M. (2019). The response of multinationals' foreign exchange rate exposure to macroeconomic news. *Journal of International Money and Finance*, 94, 32-47.
- Cheung, Y. W., & Chinn, M. D. (1999). Macroeconomic implications of the beliefs and behavior of foreign exchange traders. *Working Papers*, National Bureau of Economic Research.
- Evans, C., Pappas, K., & Xhafa, F. (2013). Utilizing artificial neural networks and genetic algorithms to build an algo-trading model for intra-day foreign exchange speculation. *Mathematical and Computer Modelling*, 58(5-6), 1249-1266.
- Fuchs, F. U. (2020). Macroeconomic determinants of foreign exchange rate exposure. *The Quarterly Review of Economics and Finance*.
- Grassberger, P., & Procaccia, I. (2004). Measuring the strangeness of strange attractors. In *The theory of chaotic attractors* (pp. 170-189). Springer, New York, NY.
- Huang, W., Lai, K. K., Nakamori, Y., & Wang, S. (2004). Forecasting foreign exchange rates with artificial neural networks: A review. *International Journal of Information Technology & Decision Making*, 3(1), 145-165.
- Kim, T. Y., Oh, K. J., Kim, C., & Do, J. D. (2004). Artificial neural networks for non-stationary time series. *Neurocomputing*, 61, 439-447.
- Kočenda, E., & Poghosyan, T. (2009). Macroeconomic

- sources of foreign exchange risk in new EU members. *Journal of Banking & Finance*, **33**(11), 2164–2173.
27. Lahmiri, S. (2016). A variational mode decomposition approach for analysis and forecasting of economic and financial time series. *Expert Systems with Applications*, **55**, 268–273.
28. Lahmiri, S. (2016). Interest rate next-day variation prediction based on hybrid feedforward neural network, particle swarm optimization, and multiresolution techniques. *Physica A: Statistical Mechanics and Its Applications*, **444**, 388–396.
29. Lahmiri, S. (2017). Modeling and predicting historical volatility in exchange rate markets. *Physica A: Statistical Mechanics and Its Applications*, **471**, 387–395.
30. Maher, J. J., & Sen, T. K. (1997). Predicting bond ratings using neural networks: A comparison with logistic regression. *Intelligent Systems in Accounting, Finance & Management*, **6**(1), 59–72.
31. Mun, K. C. (2012). The joint response of stock and foreign exchange markets to macroeconomic surprises: Using US and Japanese data. *Journal of Banking & Finance*, **36**(2), 383–394.
32. Oh, K. J., & Han, I. (2000). Using change-point detection to support artificial neural networks for interest rates forecasting. *Expert Systems with Applications*, **19**(2), 105–115.
33. Omrane, W. B., & Savaşer, T. (2016). The sign switch effect of macroeconomic news in foreign exchange markets. *Journal of International Financial Markets, Institutions and Money*, **45**, 96–114.
34. Stokes, A., & Abou-Zaid, A. S. (2012). Forecasting foreign exchange rates using artificial neural networks: A trader's approach. *International Journal of Monetary Economics and Finance*, **5**(4), 370–394.
35. Trippi, R. R., & Turban, E. (Eds.). (1992). *Neural networks in finance and investing: Using artificial intelligence to improve real world performance*. McGraw-Hill, Inc..
36. Wang, X., Liu, Z., & Wang, M. (2013). The correlation fractal dimension of complex networks. *International Journal of Modern Physics C*, **24**(05), 1350033.
37. Federal Reserve System. (2021). <https://www.federalreserve.gov/monetarypolicy/openmarket.htm>

[URL]

저 자 소 개



임 현 욱 (Hyun Wook Lim)

뱅크오브아메리카 서울지점 대표

연세대학교 투자정보공학 협동과정 통합과정 재학 중

관심 연구 분야는 인공지능기법을 활용한 외환시장, 금리시장, 채권시장 예측모델 개발 등



정 승 환 (Seung Hwan Jeong)

연세대학교 산업공학과 박사

VWAP model using Genetic Algorithm, Real Estate Auction price prediction model using Artificial Intelligence, Dynamic Guaranteed Option Hedge system using Genetic Algorithm, Pattern Matching Trading System using Dynamic time warping 등의 논문 게재

관심 연구 분야는 Analyzing financial data using Artificial Intelligence techniques and Statistical Analysis methods 등



이 희 수 (Hee Soo Lee)

세종대학교 경영학과 부교수

Journal of Banking and Finance, European Financial Management, International Review of Finance, Investment Analysts Journal 등의 주요 학술지에 논문 게재

관심 연구 분야는 Empirical asset pricing, hedge fund management, financial market integration and contagion, and investor herding behavior 등



오 경 주 (Kyong Joo Oh)

연세대학교 산업공학과 정교수

금융시장 및 데이터 분석 관련하여 약 40여 편의 해외저널 논문 게재

주요 연구 분야는 시스템트레이딩, 포트폴리오 최적화, 조기경보 시스템, 통계적 분석 모델링, 고객 관계 관리, 로보어드바이저, 핀테크 전략과 스마트 금융기술 등

〈 Abstract 〉

A Study on Foreign Exchange Rate Prediction Based on KTB, IRS and CCS Rates: Empirical Evidence from the Use of Artificial Intelligence

Hyun Wook Lim^{*}, Seung Hwan Jeong^{**}, Hee Soo Lee^{***}, Kyong Joo Oh^{****}

The purpose of this study is to find out which artificial intelligence methodology is most suitable for creating a foreign exchange rate prediction model using the indicators of bond market and interest rate market. KTBs and MSBs, which are representative products of the Korea bond market, are sold on a large scale when a risk aversion occurs, and in such cases, the USD/KRW exchange rate often rises. When USD liquidity problems occur in the onshore Korean market, the KRW Cross-Currency Swap price in the interest rate market falls, then it plays as a signal to buy USD/KRW in the foreign exchange market. Considering that the price and movement of products traded in the bond market and interest rate market directly or indirectly affect the foreign exchange market, it may be regarded that there is a close and complementary relationship among the three markets. There have been studies that reveal the relationship and correlation between the bond market, interest rate market, and foreign exchange market, but many exchange rate prediction studies in the past have mainly focused on studies based on macroeconomic indicators such as GDP, current account surplus/deficit, and inflation while active research to predict the exchange rate of the foreign exchange market using artificial intelligence based on the bond market and interest rate market indicators has not been conducted yet. This study uses the bond market and interest rate market indicator, runs artificial neural network suitable for nonlinear data analysis, logistic regression suitable for linear data analysis, and decision tree suitable for nonlinear & linear data analysis, and proves that the artificial neural network is the most suitable methodology for predicting the foreign exchange rates which are nonlinear and times series data. Beyond revealing the simple correlation between the bond market, interest rate market, and foreign exchange market, capturing the trading signals between the three markets to reveal the active correlation and prove the mutual organic movement is not only to provide foreign exchange market traders with a new trading model but also to be expected to contribute to increasing the efficiency and the knowledge management of the entire financial market.

Key Words: Knowledge management, Artificial neural network, USDKRW, CCS, KTB

^{*} Department of Investment Information Engineering, Yonsei University

^{**} Department of Industrial Engineering, Yonsei University

^{***} Department of Business Administration, Sejong University

^{****} Department of Industrial Engineering, Yonsei University